



北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

第六章 样本与抽样分布

李安南

2025年11月18日



例子

- 对于某厂家的轮胎，已经收集到了一批历史使用寿命数据，如何估计其轮胎的预期寿命？
- 对于某新研发药物，已经收集到了它在临床试验中的一批数据，如何确定其是否有效？
- 假设一个课题组想要估计不同城市人群睡眠规律上是否有差异，该如何进行？



统计与数理统计

- **Statistics** (from German: Statistik, orig. "description of a state, a country") is the **discipline** that concerns the collection, organization, analysis, interpretation, and presentation of **data**.
- **Mathematical Statistics** is the **application** of probability theory, a branch of mathematics, **to statistics**, as opposed to techniques for collecting statistical data.
- Specific **mathematical** techniques that are commonly used for this include **mathematical analysis**, **linear algebra**, **stochastic analysis**, **differential equations**, and **measure theory**. 测度论
- 数理统计中，随机变量的分布往往是未知的，人们通过实验得到许多**观察值**，对这些**数据**进行分析，从而对随机变量的分布作出**推断**

<https://en.wikipedia.org/wiki/Statistics>

https://en.wikipedia.org/wiki/Mathematical_statistics



数理统计的分类

数理统计

描述统计学

Descriptive statistics – the part of statistics that **describes** data, i.e. summarises the data and their typical properties.

任务是收集数据，包括试验设计、抽样方法等。


推断统计学

Inferential statistics – the part of statistics that **draws conclusions** from data (using some model for the data)

任务是分析数据，包括参数估计、假设检验等。



- Inferential statistics can be **contrasted** with descriptive statistics.
- Descriptive statistics is solely concerned with properties of the **observed data**, and it does not rest on the assumption that the data come from **a larger population**.
- In machine learning, the term inference is sometimes used instead to mean "make a **prediction**, by evaluating an already trained model";
- In this context inferring properties of the model is referred to as *training* or *learning*, and using a model for prediction is referred to as *inference*.





6.1 数理统计的基本概念

➤ 总体和样本

总体(population) —— 研究对象的全体组成的集合

一般地, 研究对象全体的某个(或某些)数量指标, 是一个**随机变量**(或多维随机变量)。

若为一个随机变量, 可记为 X 。例如, 某钢铁厂生产的钢锭的强度。

X 的分布函数和数字特征称为**总体的分布函数和数字特征**。



6.1 数理统计的基本概念

➤ 总体和样本

个体(individual) —— 组成总体的每一个元素(单元)
总体中每个元素的数量指标, 可以看作随机变量 X 的某个取值。用 x_i 表示。

抽样(sampling) —— 从总体中随机抽取个体, 做随机试验并记录其结果。

样本(sample) —— 从总体中抽取的**部分个体**。

假设抽取 n 个个体, 则每一个体的数量指标分别为一个随机变量, 记为: $X_1, X_2, \dots, X_n$ 则 $(X_1, X_2, \dots, X_n)$ 为样本变量, 简称**样本**。
 n 称为**样本容量**。



6.1 数理统计的基本概念

➤ 总体和样本

样本值 —— 从总体中抽取的部分个体。其数量指标的观察值 $(x_1, x_2, \dots, x_n)$ ，称为总体 X 的一个容量为 n 的样本值。

或称为样本 $(X_1, X_2, \dots, X_n)$ 的一个实现。

样本空间 —— 样本 $(X_1, X_2, \dots, X_n)$ 所有可能取值的集合。

目标是通过样本对总体的特性进行估计



6.1 数理统计的基本概念

➤ 简单随机样本

设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的一个样本，它满足：

(1) 同分布： $X_1, X_2, \dots, X_n$ 都与 X 有相同的分布

(2) 独立性： $X_1, X_2, \dots, X_n$ 相互独立

则称 $(X_1, X_2, \dots, X_n)$ 为简单随机样本。

一般地，对有限总体，采用放回抽样所得到的样本为简单随机样本，但使用不方便，因此常用不放回抽样代替。当总体中个体的数目 N 与样本容量 n 之比 $\frac{N}{n} \geq 10$ 时，可将不放回抽样近似地看作放回抽样。



6.1 数理统计的基本概念

➤ 简单随机样本

设总体 X 的分布函数为 $F(x)$, $(X_1, X_2, \dots, X_n)$ 为总体 X 的简单随机样本, 则 $(X_1, X_2, \dots, X_n)$ 的联合分布函数为

$$F_{\text{总}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

若总体 X 的概率密度函数为 $f(x)$

则 $(X_1, X_2, \dots, X_n)$ 的联合概率密度函数为

$$f_{\text{总}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

相乘



6.1 数理统计的基本概念

➤ **统计量**(statistics): 对样本进行加工, 提取有效信息

设 $(X_1, X_2, \dots, X_n)$ 是取自总体 X 的一个样本

$g(r_1, r_2, \dots, r_n)$ 为一实值连续函数, 且**不含未知参数**

则称随机变量 $g(X_1, X_2, \dots, X_n)$ 为**统计量**。

若 $(x_1, x_2, \dots, x_n)$ 是一个样本值, 则称

$g(x_1, x_2, \dots, x_n)$ 为统计量 $g(X_1, X_2, \dots, X_n)$
的一个样本值。



6.1 数理统计的基本概念

例1 $X \sim N(\mu, \sigma^2)$, μ, σ^2 是未知参数



$(X_1, X_2, \dots, X_n)$ 是一样本

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

是统计量, 其中 $X_i \sim N(\mu, \sigma^2)$

但 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$ 不是统计量。为什么?

若 μ, σ 已知, 则为统计量。





6.1 数理统计的基本概念

➤ 常用的统计量

设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的容量为 n 的样本, 称统计量

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

为**样本均值**

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

为**样本方差**

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

为**样本标准差**



6.1 数理统计的基本概念

➤ 常用的统计量

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

为样本的 k 阶原点矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

为样本的 k 阶中心矩

例如 $A_1 = \bar{X}$

总体方差 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2 \equiv S_n^2$

而样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$



6.1 数理统计的基本概念

➤ 常用的统计量

注 样本方差 S^2 与样本二阶中心矩 S_n^2 不同:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

而
$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

1) **关系式**
$$S^2 = \frac{n}{n-1} S_n^2$$



6.1 数理统计的基本概念

- 在这里我们还可以对**自由度**(degree of freedom)这个概念赋予另一种解释：
 - 一共有 n 个样本，有 n 个自由度
 - 用 S^2 估计方差 σ^2 ，自由度本应为 n
 - 但总体均值 μ 也未知，用 M_n 去估计，用掉了一个自由度，故只剩下 $n - 1$ 个自由度。



6.1 数理统计的基本概念

➤ 常用的统计量

2) 设 $E(X) = \mu$, $D(X) = \sigma^2$ 则

$$E(S_n^2) = \frac{n-1}{n} \sigma^2 \quad E(S^2) = \sigma^2$$

推导:

$$\begin{aligned} S_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) \\ &= \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + \sum_{i=1}^n \bar{X}^2 \right) = \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 \right) \\ &= \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \end{aligned}$$

$$\sum_{i=1}^n X_i = n\bar{X}$$



6.1 数理统计的基本概念

推导: $E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \mu$

$$\sum_{i=1}^n D(X_i) = n\sigma^2$$

$$D(\bar{X}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) = \frac{1}{n} \sigma^2$$

$$E(S_n^2) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2\right) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - E(\bar{X}^2)$$

$$= E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - [D(\bar{X}) + E^2(\bar{X})]$$

$E(X_i^2)$
 $= E^2(X_i) + DX_i$
 $= \sigma^2 + \mu^2$

$$= \sigma^2 + \mu^2 - \left(\frac{1}{n} \sigma^2 + \mu^2\right) = \frac{n-1}{n} \sigma^2$$



6.1 数理统计的基本概念

推导:

$$\begin{aligned} E(S^2) &= E\left[\frac{n}{n-1} S_n^2\right] = \frac{n}{n-1} E S_n^2 \\ &= \frac{n}{n-1} \frac{n-1}{n} \sigma^2 = \sigma^2 \end{aligned}$$



6.1 数理统计的基本概念

➤ 顺序统计量与极差

设 $(X_1, X_2, \dots, X_n)$ 为样本, $(x_1, x_2, \dots, x_n)$ 为样本值

$$\text{且 } x_1^* \leq x_2^* \leq \dots \leq x_n^*$$

当 $(X_1, X_2, \dots, X_n)$ 取值为 $(x_1, x_2, \dots, x_n)$ 时

定义随机变量 $X_{(k)} = x_k^*, k = 1, 2, \dots, n$

则称统计量 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 为**顺序统计量**。

其中, $X_{(1)} = \min_{1 \leq k \leq n} \{X_k\}, X_{(n)} = \max_{1 \leq k \leq n} \{X_k\}$

称 $D_n = X_{(n)} - X_{(1)}$ 为**极差**



6.1 数理统计的基本概念

例2 从一批机器零件毛坯中随机地抽取10件，测得其重量为(单位: 公斤):

210, 243, 185, 240, 215,

228, 196, 235, 200, 199

求这组样本值的均值、方差、二阶原点矩与二阶中心矩。

解 令 $(x_1, x_2, \dots, x_n)$

$= (210, 243, 185, 240, 215,$
 $228, 196, 235, 200, 199)$



6.1 数理统计的基本概念

则
$$\bar{x} = \frac{1}{10} (230 + 243 + 185 + 240 + 215 + 228 + 196 + 235 + 200 + 199)$$
$$= 217.19$$

$$s^2 = \frac{1}{9} \sum_{i=1}^{10} (x_i - \bar{x})^2 = 433.43$$

$$A_2 = \frac{1}{10} \sum_{i=1}^{10} x_i^2 = 47522.5$$

$$B_2 = \frac{1}{10} \sum_{i=1}^{10} (x_i - \bar{x})^2 = 390.0$$



6.1 数理统计的基本概念

例3 在总体 $N(52, 6.3^2)$ 中, 随机地抽取一个容量为36的样本, 求样本均值 $\bar{X}$ 落在50.8到53.8之间的概率

解

$$\bar{X} \sim N\left(52, \frac{6.3^2}{36}\right) \quad \text{下节课会证明该性质}$$

$$\text{故 } P(50.8 < \bar{X} < 53.8) = F_{\bar{X}}(53.8) - F_{\bar{X}}(50.8)$$

$$= \Phi\left(\frac{53.8 - 52}{\frac{6.3}{6}}\right) - \Phi\left(\frac{50.8 - 52}{\frac{6.3}{6}}\right)$$

$$= \Phi(1.7143) - \Phi(-1.1429)$$

$$= 0.8239$$



6.1 数理统计的基本概念


p-value: 0.957

z-value: 1.714

mean: 0

std. dev: 1

- ☐ two tails
- ☐ right tail
- ☒ left tail
- ☐ mean to z
- ☐ 2-sided mean to z





6.1 数理统计的基本概念

p-value: 0.873


z-value: 1.142

mean: 0

std. dev: 1

- ☐ two tails
- ☐ right tail
- ☒ left tail
- ☐ mean to z
- ☐ 2-sided mean to z

$$0.957 - (1 - 0.873) = 0.83$$





6.1 数理统计的基本概念

例4 设总体 X 的概率密度函数为

$$f(x) = \begin{cases} |x| & |x| < 1 \\ 0 & |x| \geq 1 \end{cases}$$


$(X_1, X_2, \dots, X_{50})$ 为总体的样本, 求

- (1) $\bar{X}$ 的数学期望与方差
- (2) $E(S^2)$
- (3) 利用中心极限定理, 估计 $P(|\bar{X}| > 0.02)$



6.1 数理统计的基本概念

$$f(x) = \begin{cases} |x| & |x| < 1 \\ 0 & |x| \geq 1 \end{cases}$$





6.1 数理统计的基本概念

解 (1)


$$E(\bar{X}) = E(X)$$

$$= \int_{-1}^1 x|x|dx = 0$$

Indefinite integral

$$\int x^2 dx = \frac{x^3}{3} + \text{constant}$$

Plot of the integral






6.1 数理统计的基本概念

解 (1)
$$D(\bar{X}) = \frac{1}{50} D(X)$$
$$= \frac{1}{50} [E(X^2) - E^2(X)]$$
$$= \frac{1}{50} 2 \int_0^1 x^2 |x| dx = \frac{1}{100}$$
$$= \frac{1}{50} \times 2 \times \left(\frac{1^4}{4} - \frac{0^4}{4} \right)$$
$$= \frac{1}{50} \times \frac{1}{2} = \frac{1}{100}$$

Indefinite integral

$$\int x^3 dx = \frac{x^4}{4} + \text{constant}$$

Plot of the integral





6.1 数理统计的基本概念


解 (2) $E(S^2) = D(X)$

$$= E(X^2) - E^2(X)$$
$$= \frac{1}{2} - 0$$
$$= \frac{1}{2}$$

Indefinite integral

$$\int x^3 dx = \frac{x^4}{4} + \text{constant}$$

Plot of the integral





6.1 数理统计的基本概念

解 (3) $\bar{X} \sim N(0, \frac{1}{100})$ $\leftarrow \bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

$$P(|\bar{X}| > 0.02) = 1 - P(|\bar{X}| \leq 0.02)$$

$$= 1 - P(-0.02 \leq \bar{X} \leq 0.02)$$

$$= 1 - [P(\bar{X} \leq 0.02) - P(\bar{X} \leq -0.02)]$$

$$= 1 - \left\{ P(\bar{X} \leq 0.02) - [1 - P(\bar{X} \leq 0.02)] \right\}$$

$$= 2(1 - P(\bar{X} \leq 0.02))$$

$$= 2 \left(1 - \Phi \left(\frac{0.02 - 0}{0.1} \right) \right) = 0.8414$$




6.1 数理统计的基本概念

p-value: 0.579
z-value: 0.2

mean: 0
std. dev: 1

- ☐ two tails
- ☐ right tail
- ☒ left tail
- ☐ mean to z
- ☐ 2-sided mean to z





北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

谢谢

