




北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

第七章 参数估计

李安南

2025年11月25日





7.1 参数的点估计

什么是参数估计?

例如, $X \sim N(\mu, \sigma^2)$

若 μ, σ^2 未知, 在抽取样本、获取样本观测值之后,

通过构造样本的函数(统计量), 给出它们的**估计值**或**取值区间**, 就是参数估计的内容。



点估计



区间估计



7.1 参数的点估计

例：在某炸药制造厂，一天中发生着火现象的次数 X 是一个随机变量，假设它服从以 $\lambda > 0$ 为的泊松分布，参数 λ 未知，现有如下样本值，试估计参数 λ 。

着火次数 k	0	1	2	3	4	5	6	≥ 7	
发生 k 次着火的天数 n_k	75	90	54	22	6	2	1	0	$\sum = 250$

解：由于 $X \sim \pi(\lambda)$ ，所以 $\lambda = E(X)$

即思路：用样本均值来估计总体均值。

$$\bar{x} = \frac{\sum_{k=0}^6 kn_k}{\sum_{k=0}^6 n_k} = \frac{1}{250} (0 \times 75 + 1 \times 90 + \dots + 6 \times 1) = 1.22$$

即 $E(X) = \lambda$ 的估计为1.22



7.1 参数的点估计

➤ 参数估计的类型

➤ 点估计

➤ 估计**未知参数的值**

➤ 区间估计

➤ 估计位置参数的**取值范围**

➤ 使得这个范围包含未知参数**真值的概率为指定的值**



7.1 参数的点估计

➤ 点估计的思想方法

设总体 X 的分布函数的形式已知，但它含有一个或多个未知参数： $\theta_1, \theta_2, \dots, \theta_k$

设 $X_1, X_2, \dots, X_n$ 为总体的一个样本

构造 k 个统计量：

$\theta_1(X_1, X_2, \dots, X_n)$	}	随机变量
$\theta_2(X_1, X_2, \dots, X_n)$		
$\dots \dots$		
$\theta_k(X_1, X_2, \dots, X_n)$		



7.1 参数的点估计

当测得一组样本值 $(x_1, x_2, \dots, x_n)$ 时, **代入**上述**统计量**, 即可得到 k 个数:

$$\left. \begin{array}{c} \hat{\theta}_1(x_1, x_2, \dots, x_n) \\ \hat{\theta}_2(x_1, x_2, \dots, x_n) \\ \dots \\ \hat{\theta}_k(x_1, x_2, \dots, x_n) \end{array} \right\} \text{数值}$$

称数 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 为未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的**估计值**

称对应的统计量 $\theta_1(X_1, X_2, \dots, X_n), \dots, \theta_k(X_1, X_2, \dots, X_n)$,
为未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的**估计量**



7.1 参数的点估计

➤ 问题

- 如何构造统计量?
- 如何评价统计量的好坏?



7.1 参数的点估计

- 常用的点估计方法: **矩法**(Method of Moments, MoM)
 - 用**样本**的 k 阶矩作为**总体**的 k 阶矩的估计量,
 - 建立含有待估计参数的方程,
 - 从而可解出待估计参数

从样本**均值**来估计总体**均值**



从**样本矩**作为相应**总体矩**的估计量



7.1 参数的点估计

即：

$$\frac{1}{n} \sum_{i=1}^n X_i \rightarrow E(X)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \rightarrow E(X^2)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^3 \rightarrow E(X^3)$$

...

记作：

$$\frac{1}{n} \sum_{i=1}^n X_i \rightarrow \hat{E}(X)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \rightarrow \hat{E}(X^2)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^3 \rightarrow \hat{E}(X^3)$$

...



7.1 参数的点估计

$$\text{由} \begin{cases} \frac{1}{n} \sum_{i=1}^n X_i \rightarrow \hat{E}(X) \\ \frac{1}{n} \sum_{i=1}^n X_i^2 \rightarrow \hat{E}(X^2) \end{cases}$$

$$\begin{aligned} \Rightarrow \hat{\mu} &= \hat{E} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \\ \hat{\sigma}^2 &= \hat{E}(X^2) - \hat{E}^2(X) = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2 \neq S^2 \end{aligned}$$

即：以样本均值估计总体均值

以样本二阶中心矩估计总体方差



7.1 参数的点估计

例1 设总体 $X \sim N(\mu, \sigma^2)$, $X_1, X_2, \dots, X_n$ 为总体的样本, 求 μ, σ^2 的矩法估计量。

解
$$\begin{aligned}\mu_1 &= E(X) = \mu & \mu_2 &= E(X^2) = D(X) + [E(X)]^2 \\ & & &= \sigma^2 + \mu^2\end{aligned}$$

$$\Rightarrow \begin{cases} \mu = \mu_1 \\ \sigma^2 = \mu_2 - \mu_1^2 \end{cases}$$



7.1 参数的点估计

分别以 A_1, A_2 代替 μ_1, μ_2 , 可以得到

$$\hat{\mu}_{\text{矩}} = A_1 = \bar{X}$$

$$\hat{\sigma}_{\text{矩}}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

$$= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$



7.1 参数的点估计


例2 设总体 $X \sim E(\lambda)$, $X_1, X_2, \dots, X_n$ 为总体的样本, 求 λ 的矩法估计量。

解

$$E(X) = \frac{1}{\lambda} \quad \text{则} \quad \hat{E}(X) = \frac{1}{\hat{\lambda}} = \bar{X}$$

$$\text{故} \quad \hat{\lambda} = \frac{1}{\bar{X}}$$

指数分布





7.1 参数的点估计

例3 设从某灯泡厂某天生产的一大批灯泡中随机地抽取了10只灯泡，测得其寿命为(单位：小时)：

1050, 1100, 1080, 1120, 1200

1250, 1040, 1130, 1300, 1200

试用矩法估计该厂这天生产的灯泡的平均寿命及寿命分布的标准差。

解
$$\hat{E}(X) = \bar{X} = \frac{1}{10} \sum_{i=1}^{10} x_i = 1147(h)$$

$$\hat{D}(X) = \hat{\sigma}^2 = \frac{1}{10} \sum_{i=1}^{10} x_i^2 - \bar{X}^2 = 6821(h^2)$$

$$\sqrt{\hat{D}(X)} = 79.25(h)$$



7.1 参数的点估计

例4 设总体 $X \sim U(a, b)$, a, b 未知, 求 a, b 的矩法估计量

解 由于 $E(X) = \frac{a+b}{2}$,

$$E(X^2) = \int_a^b x^2 \cdot \frac{1}{b-a} dx = \frac{a^2 + ab + b^2}{3}$$

$$\text{令} \begin{cases} \hat{E}(X) = \frac{\hat{a} + \hat{b}}{2} = \bar{X} \\ \hat{E}(X^2) = \frac{\hat{a}^2 + \hat{a}\hat{b} + \hat{b}^2}{3} = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$



7.1 参数的点估计

$$\begin{aligned}\mu_1 = E(X) &= \frac{a+b}{2} & \mu_2 = E(X^2) &= D(X) + [E(X)]^2 \\ & & &= \frac{(b-a)^2}{12} + \frac{(a+b)^2}{4}\end{aligned}$$

→
$$\begin{cases} a+b = 2\mu_1 \\ b-a = \sqrt{12(\mu_2 - \mu_1^2)} \end{cases}$$

求解上述方程组可得

$$a = \mu_1 - \sqrt{3(\mu_2 - \mu_1^2)}$$

$$b = \mu_1 + \sqrt{3(\mu_2 - \mu_1^2)}$$



7.1 参数的点估计

分别以 A_1, A_2 代替 μ_1, μ_2 ，可以得到

$$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} \quad \hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)}$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\hat{a}_{\text{矩}} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{b}_{\text{矩}} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$



7.1 参数的点估计

➤ 常用的点估计方法: 极大似然法

思想方法：一次试验就出现的事件有较大的概率

例如：有两个外形相同的箱子,都装有100个球


第一箱 99个白球, 1个红球

第二箱 1个白球, 99个红球

现从两箱中任取一箱, 并从箱中任取一球, 结果所取得的球是白球。

问 所取的球来自哪一箱?

答 更有可能是第一箱





7.1 参数的点估计

例5 设总体 X 服从0-1分布, 且 $P(X = 1) = p$, 用极大似然法求 p 的估计值。

解 X 的概率分布为

$$P(X = 1) = p, P(X = 0) = 1 - p$$

可以写成

$$P(X = x) = p^x(1 - p)^{1-x}, x = 0, 1$$



7.1 参数的点估计

设 $X_1, X_2, \dots, X_n$ 为总体 X 的样本,

设 $x_1, x_2, \dots, x_n$ 为总体 X 的样本值,

$$\begin{aligned} \text{则} \quad & P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) \\ &= P(X_1 = x_1) \cdot P(X_2 = x_2) \cdots P(X_n = x_n) \\ &= p^{x_1} (1-p)^{1-x_1} \cdot p^{x_2} (1-p)^{1-x_2} \cdots p^{x_n} (1-p)^{1-x_n} \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \\ &\equiv L(p) \qquad x_i = 0, 1, i = 1, 2, \dots, n \end{aligned}$$



7.1 参数的点估计

在容许的范围内选择 p , 使 $L(p)$ 最大

$$L(P) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$

注意到, $\ln L(p)$ 是 L 的单调增函数, 若某个 p 使 $\ln L(p)$ 最大, 则这个 p 必使 $L(p)$ 最大。



7.1 参数的点估计

$$\frac{d\ln L}{dp} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} \stackrel{\text{令}}{=} 0 \Rightarrow \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

$$\left(\frac{d^2 \ln L}{dp^2} = -\frac{\sum_{i=1}^n x_i}{p^2} - \frac{n - \sum_{i=1}^n x_i}{(1-p)^2} < 0 \right)$$

所以, $\hat{p} = \bar{x}$ 为所求 p 的估计值。



7.1 参数的点估计

一般地, 设 X 为离散型随机变量, 其分布律为

$$P(X = x) = f(x, \theta), \quad x = u_1, u_2, \dots, \theta \in \Theta$$

$X_1, X_2, \dots, X_n$ 为总体 X 的样本,

$x_1, x_2, \dots, x_n$ 为总体 X 的样本值,

则 $X_1, X_2, \dots, X_n$ 的概率分布为

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

$$= f(x_1, \theta) f(x_2, \theta) \cdots f(x_n, \theta)$$

记为

$$= L(x_1, x_2, \dots, x_n, \theta) \stackrel{\text{或}}{=} L(\theta) \quad x_i = u_1, u_2, \dots, i = 1, \dots, n, \theta \in \Theta$$

称 $L(\theta)$ 为样本的**似然函数(Likelihood Function)**



7.1 参数的点估计

当给定一组样本值时, $L(\theta)$ 是参数 θ 的函数, 极大似然估计法的思想就是:

选择适当的 $\theta = \hat{\theta}$, 使 $L(\theta)$ 取最大值, 即

$$\begin{aligned} & L(x_1, x_2, \dots, x_n, \hat{\theta}) \\ &= \max_{\theta \in \Theta} \{ f(x_1, \theta) f(x_2, \theta) \cdots f(x_n, \theta) \} \end{aligned}$$

则称这样得到的 $\hat{\theta} = g(x_1, x_2, \dots, x_n)$ 为参数 θ 的
极大似然估计值(Maximum Likelihood Estimate, MLE)

统计量 $\hat{\theta} = g(x_1, x_2, \dots, x_n)$ 为参数 θ 的**极大似然估计量**



7.1 参数的点估计

注1 若随机变量 X 连续, 取 $f(x_i, \theta)$ 为 X_i 的密度函数
似然函数为 $L(\theta) = \prod_{i=1}^n f(x_i, \theta)$

注2 未知参数个数可以不止一个, 如 $\theta_1, \theta_2, \dots, \theta_k$
设 X 的密度函数(或分布率)为 $f(x, \theta_1, \theta_2, \dots, \theta_k)$
则定义似然函数为

$$\begin{aligned} & L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) \\ &= L(\theta_1, \theta_2, \dots, \theta_k) = \prod_{i=1}^n f(x_i, \theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

$$-\infty < x_i < +\infty, i = 1, 2, \dots, n \quad (\theta_1, \theta_2, \dots, \theta_k) \in \Theta$$



7.1 参数的点估计

若 $L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$ 关于 $\theta_1, \theta_2, \dots, \theta_k$ 可微, 则称

$$\frac{\partial}{\partial \theta_r} L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = 0 \quad r = 1, 2, \dots, k$$

为**(对数)似然方程组**

若对于某组给定的样本值 $x_1, x_2, \dots, x_n$, 参数 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 使得似然函数取得最大值, 即

$$\begin{aligned} & L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) \\ &= \max_{(\theta_1, \theta_2, \dots, \theta_k) \in \Theta} \{L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)\} \end{aligned}$$

则称 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 为 $\theta_1, \theta_2, \dots, \theta_k$ 的**极大似然估计值**



7.1 参数的点估计

显然, $\hat{\theta}_r = g_r(x_1, x_2, \dots, x_n) \quad r = 1, 2, \dots, k$

称统计量 $\hat{\theta}_r = g_r(X_1, X_2, \dots, X_n) \quad r = 1, 2, \dots, k$

为 $\theta_1, \theta_2, \dots, \theta_k$ 的极大似然估计量



7.1 参数的点估计

例6 设总体 $X \sim N(\mu, \sigma^2)$, $x_1, x_2, \dots, x_n$ 是 X 的一组样本值, 求 μ, σ^2 的极大似然估计。

解 $L(x_1, x_2, \dots, x_n; \mu, \sigma^2)$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \frac{1}{(2\pi)^{\frac{n}{2}} (\sigma^2)^{\frac{n}{2}}} e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$


$$\ln L = - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} - \frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2)$$



7.1 参数的点估计

似然方程组

$$\begin{cases} \left(\frac{\partial}{\partial \mu} \ln L \right) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \left(\frac{\partial}{\partial (\sigma^2)} \ln L \right) = \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2(\sigma^2)} = 0 \end{cases}$$



$$\begin{cases} \hat{\mu}_{mle} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \hat{\sigma}_{mle}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases} \quad \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - n\mu)^2 = 0$$



7.1 参数的点估计

μ, σ^2 的极大似然估计量分别为

$$\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

$$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$



7.1 参数的点估计

求未知参数的极大似然估计值(量)的方法

1) 写出似然函数 L

2) 求出参数 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$, 使得

$$\begin{aligned} & L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) \\ &= \max_{(\theta_1, \theta_2, \dots, \theta_k) \in \Theta} \{L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)\} \end{aligned}$$



7.1 参数的点估计

若 L 是 $\theta_1, \theta_2, \dots, \theta_k$ 的可微函数, 解似然方程组

$$\frac{\partial}{\partial \theta_r} L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = 0, r = 1, 2, \dots, k$$

可求得未知参数的极大似然估计值 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$

然后, 再求得极大似然估计量.

若 L 不是 $\theta_1, \theta_2, \dots, \theta_k$ 的可微函数, 需用其它方法求极大似然估计值。请看下例:



7.1 参数的点估计

例7 设 $X \sim U(a, b)$, $x_1, x_2, \dots, x_n$ 是 X 的一个样本, 求 a, b 的极大似然估计值与极大似然估计量。

解 X 的密度函数为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其它} \end{cases}$$

似然函数为

$$L(x_1, x_2, \dots, x_n; a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a < x_i < b, \\ 0, & i = 1, 2, \dots, n \\ & \text{其它} \end{cases}$$



7.1 参数的点估计

似然函数只有当 $a < x_i < b, i = 1, 2, \dots, n$ 时才能获得最大值, 且 a 越大, b 越小, L 越大.

$$\begin{aligned} \text{令} \quad x_{\min} &= \min\{x_1, x_2, \dots, x_n\} \\ x_{\max} &= \max\{x_1, x_2, \dots, x_n\} \end{aligned}$$

$$\text{取} \quad \hat{a} = x_{\min}, \hat{b} = x_{\max}$$

则对满足 $a \leq x_{\min} \leq x_{\max} \leq b$ 的一切 $a < b$, 都有

$$\frac{1}{(b-a)^n} \leq \frac{1}{(x_{\max} - x_{\min})^n}$$



7.1 参数的点估计

故 $\hat{a} = x_{\min}, \hat{b} = x_{\max}$

是 a, b 的极大似然估计值。

$$X_{\min} = \min\{X_1, X_2, \dots, X_n\}$$

$$X_{\max} = \max\{X_1, X_2, \dots, X_n\}$$

分别是 a, b 的极大似然估计量。



7.1 参数的点估计

极大似然估计值的不变性原理

设 $\hat{\theta}$ 是 θ 的极大似然估计值,

$u(\theta), \theta \in \Theta$ 是 θ 的函数

且具有单值的反函数 $\theta = \theta(u), u \in U,$

则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的极大似然估计值。



7.1 参数的点估计

如：在正态分布总体 $N(\mu, \sigma^2)$ 中， σ^2 的极大似然估计值为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

$\sigma = \sqrt{\sigma^2}$ 是 σ^2 的单值函数，且具有单值的反函数，故 σ 的极大似然估计值为

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$\ln \sigma$ 的极大似然估计值为

$$\ln \sigma = \ln \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$



7.1 参数的点估计

$$P(X > t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi} \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}} e^{-\frac{(x - \bar{x})^2}{2 \cdot \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}} dx$$



7.1 参数的点估计

矩估计就不具有这个性质。

例如，设 X 的密度函数为

$$f(x) = \begin{cases} \sqrt{\frac{2}{\pi}} \frac{1}{\sigma} e^{-\frac{x^2}{2\sigma^2}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

$$E(X) = \sqrt{\frac{2}{\pi}} \sigma, \quad D(X) = \left(1 - \frac{2}{\pi}\right) \sigma^2$$

$X_1, X_2, \dots, X_n$ 为总体的样本



7.1 参数的点估计

由矩法, 令

$$E(X) = \sqrt{\frac{2}{\pi}} \sigma = \bar{X}$$

$$E(X^2) = D(X) + E^2(X) = \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

得 σ 与 σ^2 的矩法估计量为

$$\hat{\sigma} = \sqrt{\frac{\pi}{2}} \bar{X}$$

不具有不变性

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \neq (\hat{\sigma})^2$$



7.1 参数的点估计

例8 设 X 的密度函数为:

$$f(x; \theta) = \begin{cases} e^{-(x-\theta)}, & \theta \leq x < +\infty \\ 0, & \text{其它} \end{cases}$$

解 似然函数为

$$L(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \sum_{i=1}^n e^{-(x_i - \theta)}, & \theta \leq x_i < +\infty, \\ 0, & \text{其它} \quad i = 1, 2, \dots, n \end{cases}$$

当 $\theta \leq x_i < +\infty$ 时, $L(x_1, x_2, \dots, x_n; \theta) = \sum_{i=1}^n e^{-(x_i - \theta)}$

是 θ 的增函数, 故 $\theta = \min\{x_1, x_2, \dots, x_n\}$ 时,



7.1 参数的点估计

$L(x_1, x_2, \dots, x_n; \theta)$ 取最大值

当 $\theta \leq x_i < +\infty$ 不成立时,

$$L(x_1, x_2, \dots, x_n; \theta) = 0$$

故 θ 的极大似然估计为 $\min\{x_1, x_2, \dots, x_n\}$



7.1 参数的点估计

矩估计与极大似然估计对比

维度	矩估计	极大似然估计
思想基础	用样本矩逼近总体矩	最大化样本出现的概率
依赖条件	需总体矩存在	需已知总体分布形式
计算复杂度	通常较低（线性方程组）	可能较高（非线性优化）
估计性质	不一定满足不变性	满足不变性
适用场景	分布未知或模型复杂时的初步估计	分布已知、模型参数结构明确的场景



北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

谢谢

