



北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University


第九章 方差分析及回归分析

李安南

2025年12月9日



线性回归





9.3 一元线性回归分析

变量与变量之间的关系 $\left\{ \begin{array}{l} \text{确定性关系} \\ \text{相关性关系} \end{array} \right.$

确定性关系:

当自变量给定一个值时，就确定应变量的值与之对应。

如：在自由落体中，物体下落的高度 h 与下落时间 t 之间有函数关系：

$$h = \frac{1}{2} g t^2$$



9.3 一元线性回归分析

相关性关系：

变量之间的关系并不确定，而是表现为具有随机性的一种“**趋势**”。

即对自变量 x 的同一值，在不同的观测中，因变量 y 可以取不同的值，而且取值是随机的，但对应 x 在一定范围的不同值，对 y 进行观测时，可以观察到 y 随 x 的变化而呈现有一定趋势的变化。



9.3 一元线性回归分析

如：身高与体重，不存在这样的函数可以由身高计算出体重，但从统计意义上来说，身高者，体也重。

再如：父亲的身高与儿子的身高之间也有一定联系，通常父亲高，儿子也高。

回归分析——研究相关性关系的最基本，应用最广泛的方法。



9.3 一元线性回归分析

➤ 一元线性回归

设随机变量 Y 与 x 之间存在某种相关关系。这里， x 是可以控制或精确观测的变量（不是随机变量），如年龄、试验时的温度、施加的压力、电压与时间等。

由于 Y 是随机变量，对于 x 的每个确定值， Y 有相应的分布，记其分布函数为 $F(y|x)$ 。因此如果掌握了 $F(y|x)$ 随着 x 的取值而变化的规律，也就完全掌握了 Y 与 x 之间的关系了。



9.3 一元线性回归分析

然而这样做，实际中往往很难实现。

作为一种**近似**，考察 Y 的数学期望 $E(Y)$ （假设存在），其值随 x 的取值而定，它是 x 的函数，将其记为 $\mu(x)$ ，称为 Y 关于 x 的**回归函数**。

于是将讨论 Y 与 x 相关关系问题转换为讨论 $E(Y)=\mu(x)$ 与 x 的关系问题了。



9.3 一元线性回归分析

- ❖ 在实际问题中，回归函数 $\mu(x)$ 一般是未知的，需要根据试验数据去估计。
- ❖ 对于 x 取定一组不完全相同的值 $x_1, x_2, \dots, x_n$, 设分别在 x_i 处对 Y 作独立观察得到样本 (x_i, Y_i) , $i=1, 2, \dots, n$, 对应的样本观察值 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 。
- ❖ 将每对观察值 (x_i, y_i) 在直角坐标系中描出它相应的点（称为散点图），可以粗略看出 $\mu(x)$ 的形式。
- ❖ 假设 $\mu(x)$ 为线性函数： $\mu(x)=a+bx$, 此时估计 $\mu(x)$ 的问题称为求**一元线性回归**问题。



9.3 一元线性回归分析

$$\text{基本假设:} \begin{cases} Y = a + bx + \varepsilon \\ \varepsilon \text{是随机误差, 不可控制,} \\ E(\varepsilon) = 0, D(\varepsilon) = \sigma^2, \\ a, b(\text{回归系数}), \sigma^2 \text{未知.} \end{cases}$$

正态假设: $\varepsilon \sim N(0, \sigma^2)$.



9.3 一元线性回归分析

对 x 的一组不全相同的值,得到样本 $(x_1, Y_1), (x_2, Y_2), \dots, (x_n, Y_n)$

$$\text{一元线性回归模型:} \begin{cases} Y_i = a + bx_i + \varepsilon_i, i = 1, 2, \dots, n, \\ \varepsilon_i \text{相互独立}, \\ E(\varepsilon_i) = 0, D(\varepsilon_i) = \sigma^2, \\ a, b(\text{回归系数}), \sigma^2 \text{未知}. \end{cases}$$

正态假设: $\varepsilon_i \sim N(0, \sigma^2)$, 相互独立, $i = 1, 2, \dots, n$.



9.3 一元线性回归分析


➤ 一元线性回归要解决的问题

- (1) a, b 的估计;
- (2) σ^2 的估计;
- (3) 线性假设的显著性检验;
- (4) 回归系数 b 的置信区间;
- (5) 回归函数 $\mu(x) = a + bx$ 的点估计和置信区间;



9.3 一元线性回归分析

➤ a,b的估计：最小二乘估计





9.3 一元线性回归分析

➤ a,b的估计：最小二乘估计

$$Q(a,b) = \sum_{i=1}^n (y_i - a - bx_i)^2$$

求估计 $\hat{a}, \hat{b}$,

使 $Q(\hat{a}, \hat{b}) = \min_{a,b} Q(a,b)$ 。

$$\frac{\partial Q}{\partial a} = -2 \sum_{i=1}^n (y_i - a - bx_i) = 0,$$

$$\frac{\partial Q}{\partial b} = -2 \sum_{i=1}^n (y_i - a - bx_i)x_i = 0.$$



9.3 一元线性回归分析

整理得 $na + \left(\sum_{i=1}^n x_i\right)b = \sum_{i=1}^n y_i,$

$\left(\sum_{i=1}^n x_i\right)a + \left(\sum_{i=1}^n x_i^2\right)b = \sum_{i=1}^n x_i y_i.$ ——正规方程组

↓ 系数行列式

$$\begin{vmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{vmatrix} = n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i\right)^2 = n \sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$$



9.3 一元线性回归分析

记号: $\bar{y} = \frac{1}{n} \sum_i y_i$, $\bar{x} = \frac{1}{n} \sum_i x_i$, $S_{xx} = \sum_i (x_i - \bar{x})^2$,

$$S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y}), \quad S_{yy} = \sum_i (y_i - \bar{y})^2.$$

将正规方程整理得: $\hat{a} + \bar{x}\hat{b} = \bar{y}$, $S_{xx}\hat{b} = S_{xy}$.

a, b 的最小二乘估计: $\hat{a} = \bar{y} - \bar{x}\hat{b}$, $\hat{b} = S_{xy} / S_{xx}$.



9.3 一元线性回归分析

❖ 在误差为正态分布假定下，最小二乘估计等价于极大似然估计。

事实上，似然函数

$$L(a, b) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{\sigma^2} \sum_{i=1}^n (y_i - a - bx_i)^2 \right\}$$

对 $L(a, b)$ 最大化等价于对 $\sum_{i=1}^n (y_i - a - bx_i)^2$

最小化，即最小二乘估计。



9.3 一元线性回归分析

a, b 的最小二乘估计: $\hat{a} = \bar{y} - \bar{x}\hat{b}$, $\hat{b} = S_{xy} / S_{xx}$.

给定 x , $\mu(x) = a + bx$ 的估计为:

$\hat{\mu}(x) = \hat{a} + \hat{b}x$ ——经验回归函数。

方程: $\hat{y} = \hat{a} + \hat{b}x$

—— Y 关于 x 的（经验）回归方程，
其图形称为回归直线。



9.3 一元线性回归分析

性质 $\hat{a}, \hat{b}$ 分别是 a, b 的无偏估计, 从而 $E(\hat{Y}) = a + bx$ 。

证明 $\hat{b} = S_{xy}/S_{xx} = S_{xx}^{-1} \sum_i (x_i - \bar{x}) Y_i,$

$$\begin{aligned} \rightarrow E(\hat{b}) &= S_{xx}^{-1} \sum_i (x_i - \bar{x}) E(Y_i) = S_{xx}^{-1} \sum_i (x_i - \bar{x}) (a + bx_i) \\ &= b S_{xx}^{-1} \sum_i (x_i - \bar{x}) x_i = b S_{xx}^{-1} \sum_i (x_i - \bar{x})^2 = b \end{aligned}$$

$$\begin{aligned} \hat{a} = \bar{Y} - \bar{x}\hat{b} \quad \rightarrow \quad E(\hat{a}) &= E(\bar{Y}) - \bar{x}E(\hat{b}) \\ &= (a + b\bar{x}) - \bar{x}b = a \end{aligned}$$



9.3 一元线性回归分析

例5 K. Pearson收集了大量父亲身高与儿子身高的资料。其中十对如下：

父亲身高 x (吋)	60	62	64	65	66	67	68	70	72	74
儿子身高 y (吋)	63.6	65.2	66	65.5	66.9	67.1	67.4	68.3	70.1	70

求 Y 关于 x 的线性回归方程。



9.3 一元线性回归分析

计算得：

$$\bar{y} = 67.01, \bar{x} = 66.8,$$

$$\sum_i x_i^2 = 44794, \sum_i x_i y_i = 44842.4,$$

$$S_{xx} = 171.6, S_{xy} = 79.72.$$

a, b 的最小二乘估计： $\hat{a} = 35.9768, \hat{b} = 0.4646$

回归方程： $\hat{y} = 35.9768 + 0.4646x$.

或写成： $\hat{y} = 67.01 + 0.4646(x - 66.8)$.



9.3 一元线性回归分析

➤ 误差方差的估计

误差方差 σ^2 估计的意义:

- ❖ 误差方差的大小对模型的好坏有很大的影响。
- ❖ 自变量对因变量影响的大小是同误差对因变量的影响相比较的。
- ❖ 如果自变量对因变量的影响不能显著的超过误差对因变量的影响，就很难从这样的模型中提炼出有效的、有足够精度的信息。



9.3 一元线性回归分析

定义：残差 $e_i = y_i - \hat{y}_i$, $i = 1, 2, \dots, n$,

$$\text{残差平方和 } Q_e = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = Q(\hat{a}, \hat{b})$$

则 (1) $Q_e = S_{yy} - \hat{b}S_{xy}$,


(2) $\hat{\sigma}^2 = \frac{Q_e}{n-2}$ 是 σ^2 的无偏估计 (证略).



9.3 一元线性回归分析

证明: (1) $e_i = y_i - \hat{y}_i = y_i - \hat{a} - \hat{b}x_i = y_i - \bar{y} - \hat{b}(x_i - \bar{x})$

$$\begin{aligned} Q_e &= \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n [y_i - \bar{y} - \hat{b}(x_i - \bar{x})]^2 \\ &= \sum_{i=1}^n (y_i - \bar{y})^2 - 2\hat{b} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x}) + \hat{b}^2 \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= S_{yy} - 2\hat{b}S_{xy} + \hat{b}^2 S_{xx} = S_{yy} - \hat{b}S_{xy}. \end{aligned}$$


$$\hat{b} = S_{xy} / S_{xx}$$



9.3 一元线性回归分析

例6 求例5中误差方差的无偏估计。

父亲身高 x (吋)	60	62	64	65	66	67	68	70	72	74
儿子身高 y (吋)	63.6	65.2	66	65.5	66.9	67.1	67.4	68.3	70.1	70

计算得：

$$\bar{y} = 67.01, \sum_i y_i^2 = 44941.93, S_{yy} = 38.529.$$

$$\text{又已知 } S_{xy} = 79.72, \hat{b} = 0.4646.$$

$$Q_e = S_{yy} - \hat{b}S_{xy} = 1.491,$$

所以， σ^2 的无偏估计 $\hat{\sigma}^2 = Q_e / (n - 2) = 0.186$.



9.3 一元线性回归分析

➤ 线性假设的显著性检验

- ❖ 采用最小二乘法估计参数 a 和 b ，并不需要事先知道 Y 与 x 之间一定具有相关关系，
- ❖ 即使是平面图上一堆完全杂乱无章的散点，也可以用公式求出回归方程。
- ❖ 因此 $\mu(x)$ 是否为 x 的线性函数，一要根据专业知识和实践来判断，
- ❖ 二要根据实际观察得到的数据用假设检验方法来判断。



9.3 一元线性回归分析

即要检验假设 $H_0: b = 0$, $H_1: b \neq 0$,

若原假设被拒绝, 说明回归效果是显著的, 否则, 若接受原假设, 说明Y与x不是线性关系, 回归方程无意义。

回归效果不显著的原因可能有以下几种:

- ❖ 影响Y取值的, 除了x, 还有其他不可忽略的因素;
- ❖ $E(Y)$ 与x的关系不是线性关系, 而是其他关系;
- ❖ Y与x不存在关系。



9.3 一元线性回归分析

检验假设 $H_0 : b = 0, H_1 : b \neq 0$, 拒绝域形式: $|\hat{b}| \geq c$ 。

假定: ε_i 独立同服从 $N(0, \sigma^2)$ 分布 ($i = 1, 2, \dots, n$)。

则可以证明 (1) $\hat{b} \sim N(b, S_{xx}^{-1} \sigma^2)$;

$$(2) \frac{(n-2)\hat{\sigma}^2}{\sigma^2} = \frac{Q_e}{\sigma^2} \sim \chi^2(n-2);$$

(3) $\hat{b}$ 与 Q_e 独立。



9.3 一元线性回归分析

$$\text{故 } \frac{\hat{b} - b}{\sqrt{\sigma^2 / S_{xx}}} \bigg/ \sqrt{\frac{(n-2)\hat{\sigma}^2}{\sigma^2}} \bigg/ (n-2) \sim t(n-2),$$

$$\text{当 } H_0 \text{ 为真即 } b = 0 \text{ 时, } t = \frac{\hat{b}}{\hat{\sigma}} \sqrt{S_{xx}} \sim t(n-2),$$

$$\text{水平为 } \alpha \text{ 的检验拒绝域: } |t| = \frac{1}{\hat{\sigma}} |\hat{b}| \sqrt{S_{xx}} \geq t_{\alpha/2}(n-2).$$



9.3 一元线性回归分析

例7 检验例5中回归效果是否显著，取 $\alpha=0.05$ 。

父亲身高 x (吋)	60	62	64	65	66	67	68	70	72	74
儿子身高 y (吋)	63.6	65.2	66	65.5	66.9	67.1	67.4	68.3	70.1	70

解 $\hat{b} = 0.4646$, $S_{xx} = 171.6$, $\hat{\sigma}^2 = 0.186$.

查表得: $t_{\alpha/2}(n-2) = t_{0.025}(8) = 2.306$.



9.3 一元线性回归分析

因此假设 $H_0 : b = 0$ 的检验拒绝域为：

$$|t| = \frac{|\hat{b}|}{\hat{\sigma}} \sqrt{S_{xx}} \geq 2.306.$$

计算得, $|t| = \frac{|0.4646|}{\sqrt{0.186}} \sqrt{171.6} = 14.1 > 2.306.$

故拒绝 $H_0 : b = 0$, 认为回归效果是显著的。



9.3 一元线性回归分析

➤ 回归系数b的置信区间

当回归效果显著时，常需要对回归系数b作区间估计。

由于 $\frac{\hat{b} - b}{\hat{\sigma}} \sqrt{S_{xx}} \sim t(n - 2)$,

所以 $\frac{|\hat{b} - b|}{\hat{\sigma}} \sqrt{S_{xx}} \leq t_{\frac{\alpha}{2}}(n - 2)$

即b的置信水平 $1 - \alpha$ 的置信区间:

$$\left(\hat{b} \pm t_{\frac{\alpha}{2}}(n - 2) \times \frac{\hat{\sigma}}{\sqrt{S_{xx}}} \right)$$



9.3 一元线性回归分析

例如例5中 b 的置信水平为0.95的置信区间为：

$$\left(0.4646 \pm 2.306 \times \sqrt{\frac{0.186}{171.6}} \right) = (0.389, 0.541).$$



9.3 一元线性回归分析

➤ 回归函数 $\mu(x) = a + bx$ 函数值的点估计和置信区间

对给定的 x_0 , $\mu(x_0) = a + bx_0$ 的点估计为 $\hat{y}_0 = \hat{\mu}(x_0) = \hat{a} + \hat{b}x_0$.

则有(1)相应的估计量 $\hat{Y}_0 = \hat{a} + \hat{b}x_0$ 是 $\mu(x_0) = a + bx_0$ 无偏估计,

(2) $\mu(x_0) = a + bx_0$ 的置信水平为 $1-\alpha$ 的置信区间为:

$$\left(\hat{Y}_0 \pm t_{\alpha/2}(n-2) \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} \right)$$

证明: (1)因为 $E(\hat{b}) = b, E(\hat{a}) = a$,

所以 $E(\hat{Y}_0) = E(\hat{a} + \hat{b}x_0) = a + bx_0$.即为无偏估计



9.3 一元线性回归分析

(2) 可以证明: $\hat{Y}_0 \sim N(a + bx_0, \left(\frac{1}{n} + (x_0 - \bar{x})^2 S_{xx}^{-1} \right) \sigma^2)$.

又有, $\frac{(n-2)\hat{\sigma}^2}{\sigma^2} = \frac{Q_e}{\sigma^2} \sim \chi^2(n-2)$; 且 $\hat{Y}_0$ 与 Q_e 独立。

于是
$$\frac{\hat{Y}_0 - a + bx_0}{\sigma \sqrt{\frac{1}{n} + (x_0 - \bar{x})^2 S_{xx}^{-1}}} \bigg/ \sqrt{\frac{(n-2)\hat{\sigma}^2}{\sigma^2} / (n-2)} \sim t(n-2),$$



9.3 一元线性回归分析

$$\text{即 } \frac{\hat{Y}_0 - a + bx_0}{\hat{\sigma} \sqrt{\frac{1}{n} + (x_0 - \bar{x})^2 S_{xx}^{-1}}} \sim t(n-2),$$

所以, $\mu(x_0) = a + bx_0$ 的置信水平为 $1-\alpha$ 的置信区间为:

$$\left(\hat{Y}_0 \pm t_{\alpha/2}(n-2) \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} \right)$$



9.3 一元线性回归分析

例8 在例5中F.Galton曾断言“儿子身高会受到父亲身高的影响，但身高偏离父代平均水平的父亲，其儿子身高的影响有回归到子代平均水平的趋势。”试问例5这组数据能证实这一论断吗($\alpha=0.05$)?并给出 $x=69$ 吋时, y 的预测区间。

解 由前例可知 $\hat{a} = 35.9768, \hat{b} = 0.4646$
 $S_{xx} = 171.6, \hat{\sigma}^2 = 0.186, \bar{x} = 66.8.$



9.3 一元线性回归分析

(1) 回归到平均水平的趋势，即检验

$$H_0 : b = 1, H_1 : b < 1$$

$$\text{因为 } \frac{\hat{b} - b}{\hat{\sigma}} \sqrt{S_{xx}} \sim t(n-2),$$

所以，当 H_0 为真即 $b = 1$ 时， $t = \frac{\hat{b} - 1}{\hat{\sigma}} \sqrt{S_{xx}} \sim t(n-2)$,

从而水平 α 的检验拒绝域： $t = \frac{\hat{b} - 1}{\hat{\sigma}} \sqrt{S_{xx}} \leq -t_{\alpha}(n-2)$ 。

$$\text{经计算, } t = \frac{\hat{b} - 1}{\hat{\sigma}} \sqrt{S_{xx}} = \frac{0.4646 - 1}{\sqrt{0.186}} \sqrt{171.6} = -16.2317$$

$$t < -t_{0.05}(8) = -1.8595, \text{ 拒绝 } H_0, \text{ 认为 } b < 1.$$



9.3 一元线性回归分析

(2) 当 $x_0 = 69$ 时, $\hat{y}_0 = \hat{a} + \hat{b}x_0 = 68.03$

$$t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} = 2.306 \times \sqrt{0.186} \sqrt{\frac{1}{10} + \frac{(69-66.8)^2}{171.6}} = 0.356$$


所以, $\mu(69)$ 的置信水平为0.95的置信区间为:(67.674, 68.386).

(3) $x_0 = 69$ 时, Y_0 的置信水平为0.95的预测区间为:
(66.974, 69.086).

其中 $t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} = 1.056$.



多元线性回归





北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

谢谢

