



北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

第十一章 概率在数据科学的应用

张子威

2025年12月19日



1

数据与关联规则挖掘

2

贝叶斯分类


3

从相关性到因果性



四个科学范式

➤ 在人类科学发展中，大致历经四个范式演变





➤ 第五范式：智能科学（AI for Science）？



❖ 第一范式：实验/经验科学 (Empirical Science)

- 时间：从几千年前至近几百年
- 特点：以观察和实验为主，描述自然现象
 - 阿基米德浮力定律
 - 伽利略比萨斜塔实验
- 对应基础：四则运算、简单等式等





❖ 第二范式：理论科学 (Theoretical Science)

- 时间：近几百年更多出现理论分支


- 特点：利用模型和归纳

- 开普勒定律

- 麦克斯韦方程

- 相对论

- 对应基础：微积分等



$$\sum_i \mathbf{F}_i = 0 \Rightarrow \frac{d\mathbf{v}}{dt} = 0;$$

$$\mathbf{F} \propto m\mathbf{a};$$



$$\sum \mathbf{F}_{AB} = -\sum \mathbf{F}_{BA}$$

名称	微分形式	积分形式
高斯定律	$\nabla \cdot \mathbf{E} = \frac{\rho}{\epsilon_0}$	$\oiint_S \mathbf{E} \cdot d\mathbf{s} = \frac{Q}{\epsilon_0}$
高斯磁定律	$\nabla \cdot \mathbf{B} = 0$	$\oiint_S \mathbf{B} \cdot d\mathbf{s} = 0$
法拉第感应定律	$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t}$	$\oint_L \mathbf{E} \cdot d\boldsymbol{\ell} = -\frac{d\Phi_B}{dt}$
麦克斯韦-安培定律	$\nabla \times \mathbf{B} = \mu_0 \mathbf{J} + \mu_0 \epsilon_0 \frac{\partial \mathbf{E}}{\partial t}$	$\oint_L \mathbf{B} \cdot d\boldsymbol{\ell} = \mu_0 I + \mu_0 \epsilon_0 \frac{d\Phi_E}{dt}$



❖ 第三范式：计算科学 (Computational Science)


- 时间：20世纪出现了计算分支
- 特点：用数学构建模型、定量分析方法复杂现象进行仿真
 - 天气预报
 - 发动机仿真
 - 分子动力学模拟
- 对应基础：方程求解、密度泛函、有限元等





❖ 第四范式： 数据科学

- 时间：21世纪初至今天
- 特点：数据爆炸将理论、实验、计算统一起来、学科交叉
- 例子：上网课对教学的影响



- 对应基础：概率统计、数据挖掘、机器学习等



啤酒尿布

- 美国一家大型连锁超市通过分析来自25家分店，超过1200万个购物车的信息，得到一个有趣的结论：
尿布和啤酒经常被一同购买。
- 于是，尝试推出了将啤酒和尿布摆在一起的促销手段，使尿布和啤酒的销量都大幅增加了。
- 为什么呢？





关联规则挖掘

- **关联规则挖掘**(association rule mining)
- 例：给定一系列购物记录，捕捉其中商品共同出现的规律，从而预测其他商品的购买

购物记录	商品列表
1	面包，牛奶
2	面包，尿布，啤酒，鸡蛋...
3	牛奶，尿布，啤酒，可乐...
4	面包，牛奶，尿布，啤酒...
5	面包，牛奶，尿布，可乐...
	...

关联规则

{尿布} → {啤酒},
{牛奶, 面包} → {鸡蛋, 可乐},
{啤酒, 面包} → {牛奶},
...

注意，关联只是代表**相关性**，而非**因果性**
(第3小节课会介绍更多因果性)



关联规则的数学定义

➤ 项集(Itemset):

- 一个或者多个项的集合
 - 例: {牛奶}, {啤酒, 尿布}
- k项集: 包含k个物品

➤ 支持度计数(support count)

- 一个项集出现的次数
- 例: $\sigma(\{\text{尿布}, \text{啤酒}\}) = 3$

➤ 支持度(support)

- 一个项集出现的比率
- 例: $s(\{\text{尿布}, \text{啤酒}\}) = 3/5$

➤ 频繁项集(frequent itemset)

- 支持度大于一个阈值 $minsup$ 的项集

购物记录	商品列表
1	面包, 牛奶
2	面包, 尿布, 啤酒, 鸡蛋...
3	牛奶, 尿布, 啤酒, 可乐...
4	面包, 牛奶, 尿布, 啤酒...
5	面包, 牛奶, 尿布, 可乐...



关联规则的数学定义

➤ 关联规则：反应两个项集间关系的模式

➤ 记为 $X \rightarrow Y$, X, Y 均为项集

➤ 例：{尿布} $\rightarrow$ {啤酒}

{牛奶, 面包} $\rightarrow$ {鸡蛋, 可乐}

➤ 规则的支持度(support)

➤ 同时出现 X 和 Y 的支持度

$$\text{support}(X \rightarrow Y) = P(X \cup Y)$$

➤ 例： $\text{support}\{\{\text{尿布}\} \rightarrow \{\text{啤酒}\}\} = s(\{\text{尿布}, \text{啤酒}\}) = 3/5$

购物记录	商品列表
1	面包, 牛奶
2	面包, 尿布, 啤酒, 鸡蛋...
3	牛奶, 尿布, 啤酒, 可乐...
4	面包, 牛奶, 尿布, 啤酒...
5	面包, 牛奶, 尿布, 可乐...



关联规则的数学定义

➤ **关联规则**：反应两个项集间关系的模式

➤ 记为 $X \rightarrow Y$, X, Y 均为项集

➤ 例：{尿布} $\rightarrow$ {啤酒}

{牛奶, 面包} $\rightarrow$ {鸡蛋, 可乐}

➤ **规则的支持度(support)**

➤ **规则的置信度(confidence)**

➤ 在包含项集 X 的记录里, 出现 Y 的比例

$$confidence(X \rightarrow Y) = P(Y|X) = \frac{support(X \rightarrow Y)}{support(X)} = \frac{\sigma(X \cup Y)}{\sigma(X)}$$

➤ 例： $confidence\{\{尿布\} \rightarrow \{啤酒\}\} = \frac{\sigma(\{尿布, 啤酒\})}{\sigma(\{尿布\})} = 3/4$

购物记录	商品列表
1	面包, 牛奶
2	面包, 尿布, 啤酒, 鸡蛋...
3	牛奶, 尿布, 啤酒, 可乐...
4	面包, 牛奶, 尿布, 啤酒...
5	面包, 牛奶, 尿布, 可乐...



关联规则的数学定义

➤ **关联规则**：反应两个项集间关系的模式

➤ 记为 $X \rightarrow Y$, X, Y 均为项集

➤ 例：{尿布} $\rightarrow$ {啤酒}

{牛奶, 面包} $\rightarrow$ {鸡蛋, 可乐}

➤ **规则的支持度(support)**

➤ **规则的置信度(confidence)**

➤ **强关联规则**：满足最小支持度阈值和最小置信度阈值

➤ 例：若阈值均为0.5, 则{尿布} $\rightarrow$ {啤酒}是一个强关联

➤ 为什么不能只满足置信度？

考虑如果某一个商品仅出现一次

购物记录	商品列表
1	面包, 牛奶
2	面包, 尿布, 啤酒, 鸡蛋...
3	牛奶, 尿布, 啤酒, 可乐...
4	面包, 牛奶, 尿布, 啤酒...
5	面包, 牛奶, 尿布, 可乐...



关联规则挖掘

- **关联规则挖掘**：给定一系列交易记录数据：
 - (1) 找到所有支持度大于一个阈值 $minsup$ 的**频繁项集**
 - (2) 找到由频繁项集产生的**强关联规则**（大于最小支持度和最小置信度阈值）
- 挑战：交易数据量大 + 频繁项集数量多
- 为解决上述问题，关联规则挖掘发展出许多著名算法
 - A-Priori [\[PDF\] Fast Algorithms for Mining Association Rules](#)
[R Agrawal](#) - 1994 - [mahoto.wordpress.com](#)
Fast Algorithms for Mining Association Rules Fast Algorithms for Mining Association Rules
☆ Save 📄 Cite Cited by 31738 Related articles 🔗
 - FP-Tree [Mining frequent patterns without candidate generation](#)
[J Han, J Pei, Y Yin](#) - ACM sigmod record, 2000 - [dl.acm.org](#)
☆ Save 📄 Cite Cited by 10760 Related articles All 58 versions
 -
- 基础：概率与统计



关联规则挖掘应用例子(1)

➤ 市场营销

- 假设挖掘出的规则是 {牛奶} → {咖啡}
- 关注于**被影响者(consequent)**: 可以用于决定如何提升咖啡的销量 (例如货架的摆放等)
- 关注于**影响者(antecedent)**: 可以用于决定关于牛奶的营销策略 (例如, 通过促销牛奶, 即使牛奶本身不赚钱, 但有可能通过咖啡赚钱)
 - 注意, **关联规则并非因果性**, 不一定成立
- 关注于**两者**: 可以通过组合多个规则, 间接影响
 - 例如, 若还有一个规则为{面包} → {牛奶}



关联规则挖掘应用例子(2)

- 在各行各业都有可能的应用
- 例1 穿衣搭配。通过分析专家达人或网络上走红的搭配数据，推荐优质的穿衣模型。
- 例2 交通事故成因。通过分析道路交通事故的多维度因素，分析可能的成因。
- 例3 球员最优组合。通过分析历史比赛数据，挖掘可能对比赛结果影响的因素。

.....




数据科学应用案例：群组分析

- **社交群组**在日常生活中很常见：微信群、QQ群、钉钉等
- 群组分析有很多用处：**推荐系统**、**违规检测**、**态势预测**...



社交群组



社交影响



集体行为



数据科学应用案例：群组分析

➤ 2014年与某社交平台合作，获取了一批匿名处理后的数据

群名	类别	人数	消息	稠密度	性别比	平均年龄	年龄差	地域集中度	手机比例	会话数	无回应比例	图片比例
*军团	1	74	115	0.086264	0.833333	26.31343	4.22928	0.228571	0.208696	20	0.55	0.026087
** .net/bbs	2	133	2112	0.011107	0.961832	30.31967	4.66986	0.110236	0.16714	327	0.53211	0.037879
**酒吧	3	63	315	0.051715	0.882353	26.68182	6.40941	0.222222	0.088889	23	0.434783	0.069841
**嘉园	3	73	2	0.010274	0.57971	27.5	9.04252	0.40678	0	2	1	0
**無黑\導、1 群	1	73	4	0.024163	0.75	23.41538	4.69989	0.287879	0.5	4	1	0.25
**工作联系基地	5	91	14	0.006105	0.901639	29.40909	2.85496	0.340426	0.142857	7	1	0
**DOTA粉丝群	1	85	91	0.035014	0.903614	26.1125	4.41586	0.617284	0.153846	30	0.7	0.065934
**联盟	1	60	22	0.038136	0.807692	29.7381	4.61910	0.357143	1	4	0.5	0.045455
**赤水贴吧	1	55	1940	0.091919	0.759259	24.41509	4.65177	0.745455	0.548969	193	0.414508	0.017526


➤ 人工标注了类别信息

类别	主题	数量
1	游戏	484
2	学校	300
3	生活	196
4	金融	425
5	企业	635



数据科学应用案例：群组分析

- 问题：不同类型群组在年龄上是否存在差异？
- 简单分析：箱型图 (box-plot) 可视化



- 看上去似乎有一定区别。如何严格区分？
- 方差分析



数据科学应用案例：群组分析

- H_0 : 不同类别的群, 平均年龄的平均值全部相同
- H_1 : 不同类别的群, 平均年龄的平均值不全相同
- 然后进行单因素方差分析:

ANOVA Table					
Source	SS	df	MS	F	Prob>F
Groups	12782.9	4	3195.73	171.51	1.08209e-126
Error	37918.6	2035	18.63		
Total	50701.5	2039			

- 结果表示, 应拒绝原假设, 即不同类型群平均年龄有区别



数据科学应用案例：群组分析

- 人工标注群类别费时费力，能否设计一个**自动化方案**？
- 任务转换成利用群组特征进行分类的**多类别分类问题**
 - 将数据集按照70%-30%比例划分为训练集和测试集
 - 首先，尝试将其转换为5个二分类问题，使用逻辑回归

类别	1	2	3	4	5	总和
样本量	484	300	196	425	635	2040
准确率	0.65	0.17	0.41	0.74	0.78	0.62

- 接着尝试使用梯度提升分类器Gradient Boosting Classifier

超参数	10	20	50	100
训练集准确率	0.72	0.74	0.81	0.89
测试集准确率	0.63	0.65	0.66	0.64


- 效果仍不理想，且产生**过拟合 (overfitting)**



数据科学应用案例：群组分析

➤ 原因：

- 原始特征（年龄、性别等）不足以提供一个好的表征空间
- 表征学习（Representation Learning）：



- 此外，未考虑群组本身特性，例如群内成员间的关系
- 基于上述观察，设计群组表征模型并取得了较好的结果

Perceiving Group Themes from Collective Social and Behavioral Information

Peng Cui, Tianyang Zhang
Department of Computer Science
Tsinghua University, Beijing, China

Fei Wang
Department of Computer Science
University of Connecticut, USA

Peng He
Department of Social Network Operation
Tencent Technology, Shenzhen, China

Abstract

Collective social and behavioral information commonly exists in nature. There is a widespread intuitive sense that the characteristics of these social and behavioral information are to some extent related to the themes (or semantics) of the activities or targets. In this paper, we explicitly validate the interplay of collective social behavioral information and group themes using a large scale real dataset of online groups, and demonstrate the possibility of perceiving group themes from collective social and behavioral information. We propose a Regularized miXed Regression (REXER) model based on


years, social networks, especially the online social groups, digitally and continuously record the collective behaviors and social profiles of users, as well as the themes of social groups in an unprecedented level. This provides precious opportunities to investigate the link between the collective social and behavioral information of group members and the group themes. The interplay between semantics and human behaviors is of significant interest to both academia to understand human collective behaviors and industry to serve customers more intelligently.

Social groups and the collective behaviors of their mem-



数据科学应用案例：群组分析

➤ 总结：数据挖掘流程



➤ 许多环节均涉及概率与统计工具！



北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

谢谢

本课件仅供课上教学使用，对以下参考资料一并表示感谢：
清华大学 朱文武老师课件《大数据分析》
韩家炜，坎伯《数据挖掘：概念与技术》

