北京航空航天大学计算机学院
School of Computer Science and Engineering, Beihang University

第十一章 概率在数据科学的应用

张子威

2025年12月19日

提纲

1 数据与关联规则挖掘

2 贝叶斯分类

3 从相关性到因果性

分类任务

- **分类**是最常见的一类机器学习/人工智能任务
  - 例子：鸟类图片分类
  - 任务：给定一张图片，输出它的类别
  - 模型：$F($  $)$ →类别的概率分布
  - 训练数据：图片以及它们对应的标签

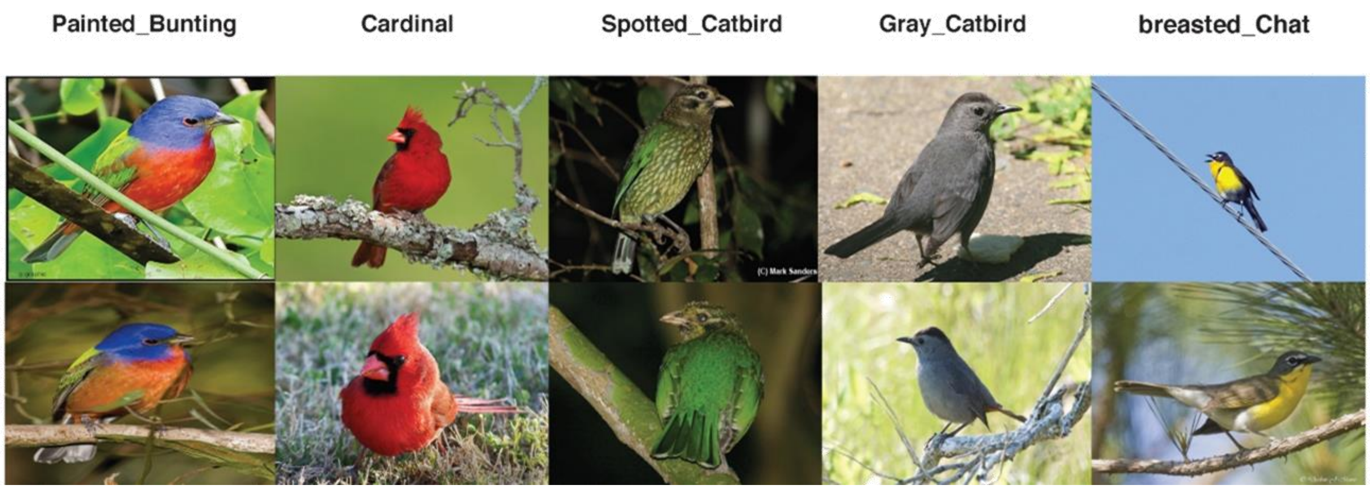

  - 训练：根据训练数据，优化模型
  - 测试：评估模型的准确性

分类任务

- 分类是最常见的一类机器学习/人工智能任务
  - 例子：垃圾邮件分类
  - 任务：给定一封邮件，判定它是否为垃圾邮件
  - 模型：$F($  $)$ →垃圾邮件概率
  - 训练数据：历史邮件内容以及它们对应的标签

Dear Sir. First, I must solicit your confidence in this transaction, this is by virture of its nature as being utterly confidencial and top secret. …	TO BE REMOVED FROM FUTURE MAILINGS, SIMPLY REPLY TO THIS MESSAGE AND PUT "REMOVE" IN THE SUBJECT. 99 MILLION EMAIL ADDRESSES FOR ONLY $99	Ok, Iknow this is blatantly OT but I'm beginning to go insane. Had an old Dell Dimension XPS sitting in the corner and decided to put it to use, I know it was working pre being stuck in the corner, but when I plugged it in, hit the power nothing happened.
✗	✗	✓

  - 训练：根据训练数据，优化模型
  - 测试：评估模型的准确性

垃圾邮件分类问题

- 输入：$x = [x_1, x_2 \dots, x_n]$, x_i是邮件中第i个词
- 输出：$y = 1$（垃圾邮件）或$y = 0$(非垃圾邮件)
- 问题分析：邮件主题很大程度上决定了邮件内容
  - 垃圾邮件：免费，推销，”$”符号，等等
- 将其建模为一个生成式模型：

$$P(y, x_1, x_2, \dots, x_n)$$

在本例中，其和判别模型有很大联系：

$$P(y|x_1, x_2, \dots, x_n) = \frac{P(y, x_1, x_2, \dots, x_n)}{P(x_1, x_2, \dots, x_n)}$$

垃圾邮件分类问题

- 朴素贝叶斯(Naïve Bayes)+词袋模型(Bag of Words)
  - 假定单词之间互不影响，词语位置也不影响
  - 但是否为垃圾邮件会影响用词

$$P(y, x_1, x_2, \dots, x_n) = P(y)P(x_1, x_2, \dots, x_n|y)$$
$$= P(y)\prod_i P(x_i|y)$$

  - $P(y)$：是否为垃圾邮件的先验概率
  - $P(x_i|y)$：垃圾邮件与非垃圾邮件的用词区别
    - 如何估算？从训练集中统计！

$P(x_i|y=0)$

the	paper	you	submit	is	accepted	…
0.0156	0.0153	0.0115	0.0095	0.0093	0.0086	

$P(x_i|y=1)$

the	money	of	your	deposit	from	…
0.0210	0.0133	0.0069	0.0250	0.0385	0.0082	

垃圾邮件分类问题

- 推断举例： Gray would you like to lose weight while you sleep

单词	$P(x_i \vert y=1)$	$P(x_i \vert y=0)$	$\log P(y=1,\dots,x_i)$	$\log P(y=0,\dots,x_i)$
(先验)	0.33333	0.66666	-1.1	-0.4

- 分类概率：

$$P(y=1|x)=\frac{P(y=1,x)}{P(x)}=\frac{P(y=1,x)}{P(y=1,x)+P(y=0,x)}=\frac{e^{-76.0}}{e^{-76.0}+e^{-80.3}}=98.7\%$$

过拟合与拉普拉斯平滑

- 由于训练样本局限，存在一些 $P(x|y)=0$的情况
- 例：邮件分类（$y=1$为垃圾邮件， $y=0$为正常邮件）
  - 部分词语相对概率

$$\frac{P(x|y=1)}{P(x|y=0)}$$

south-west	:	∞
nation	:	∞
morally	:	∞
nicely	:	∞
extent	:	∞
seriously	:	∞
…		

$$\frac{P(x|y=0)}{P(x|y=1)}$$

screens	:	∞
minute	:	∞
guaranteed	:	∞
$205.00	:	∞
delivery	:	∞
signature	:	∞
…		

过拟合与拉普拉斯平滑

- 原因：条件概率估算过于依赖训练数据
  - 不是出现“minute” “$205”的均是垃圾邮件
  - 同理，不是出现“south-west”的均是正常邮件
  - 甚至，如果训练集没有出现过的词
- 称为过拟合（overfitting）现象
  - 定义：模型过于紧密或精确地匹配训练数据集，以致于无法良好地拟合其他数据或预测未来的观察结果
  - 例：

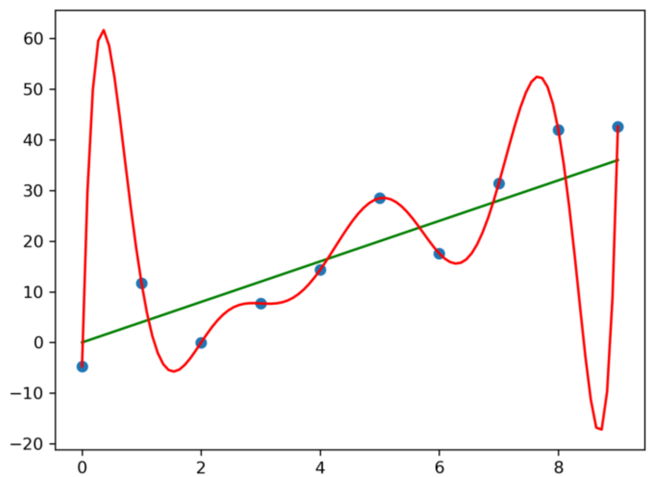

过拟合与拉普拉斯平滑

- 之前采用的是最大似然估计(Maximum Likelihood Estimate)

$$P_{MLE}(x) = \frac{\text{包含}x\text{的样本数}}{\text{总样本数}}$$

- 最大似然估计的潜在问题：以掷硬币为例(不一定均匀)
  - 如果仅掷硬币1次为正面， 你觉得P(正面)是多少?
  - 若掷硬币10次，8次为正面，你觉得P(正面)是多少
  - 若掷硬币10万次，8万次为正面，你觉得P(正面)是多少
- 解决思想：参数的贝叶斯估计 (Bayesian estimation)
  - 许多问题中，我们有对于参数的先验（例如硬币正面的概率)
  - 通过实验，不断修正对于先验的认知
  - 结果不充分时，主要依赖先验；随实验增多，愈加相信数据

过拟合与拉普拉斯平滑

➢ 拉普拉斯平滑

- ➢ 假设每个可能得取值已经出现过k次

$$P_{LAP,k}(x) = \frac{c(x)+k}{N+k|X|}$$

➢ 例子：假设投掷硬币三次的结果：

- ➢ $P_{MLE}(x) = P_{LAP,0} \quad =< \frac{2}{3}, \frac{1}{3} >$

$$P_{LAP,1} \quad =< \frac{3}{5}, \frac{2}{5} >$$

$$P_{LAP,100} =< \frac{102}{203}, \frac{101}{203} >$$

k值越大，先验越强

➢ 拉普拉斯平滑应用于条件概率估算：

$$P_{LAP,k}(x|y) = \frac{c(x,y)+k}{c(y)+k|X|}$$

过拟合与拉普拉斯平滑

➢ 拉普拉斯平滑后的概率

($y=1$为垃圾邮件， $y=0$为正常邮件)

$$\frac{P(x|y=1)}{P(x|y=0)}$$

south-west	:	10.3
nation	:	9.5
morally	:	7.8
nicely	:	5.7
extent	:	4.6
seriously	:	3.1
…		

$$\frac{P(x|y=0)}{P(x|y=1)}$$

screens	:	28.8
minute	:	27.3
guaranteed	:	25.2
$205.00	:	20.3
delivery	:	18.2
signature	:	17.5
…		

购买预测问题

- ➢根据用户资料，判断其购买电脑的概率
- ➢ 训练数据：

Age	Income	Student	Credit_rating	Buys_computer
<=30	high	no	fair	no
<=30	high	no	excellent	ho
30...40	high	ho	fair	yes
>40	medium	no	fair	yes
>40	low	yes	fair	yes
>40	low	yes	excellent	no
31...40	low	yes	excellent	yes
<=30	medium	no	fair	no
<=30	low	yes	fair	yes
>40	medium	yes	fair	yes
<=30	medium	yes	excellent	yes
31...40	medium	no	excellent	yes
31...40	high	yes	fair	yes
>40	medium	no	excellent	no

- ➢ 目标：预测样本购买电脑的概率

X =(age<=30, Income=medium, Student=yes, Credit_rating= Fair)

购买预测问题

➢问题转化：

$$P(\text{buys=“yes”}|\text{X})=\frac{P(\text{buys=“yes”,X})}{P(\text{X})}=\frac{P(\text{buys=“yes”,X})}{P(\text{buys=“yes”,X})+P(\text{buys=“no”,X})}$$

$$\begin{aligned}P(\text{buys=“yes”, X})&=P(\text{buys=“yes”})*P(\text{X}|\text{buys=“yes”})\\&=P(\text{buys=“yes”})*\prod_i P(\text{X}_i|\text{buys=“yes”})\\&=P(\text{buys=“yes”})*P(\text{Age}|\text{buys=“yes”})*P(\text{Income}|\text{buys=“yes”})\\&\quad*P(\text{Student}|\text{buys=“yes”})*P(\text{Credit}|\text{buys=“yes”})\end{aligned}$$

$$\begin{aligned}P(\text{buys=“no”, X})&=P(\text{buys=“no”})*P(\text{X}|\text{buys=“no”})\\&=P(\text{buys=“no”})\prod_i P(\text{X}_i|\text{buys=“no”})\\&=P(\text{buys=“no”})*P(\text{Age}|\text{buys=“no”})*P(\text{Income}|\text{buys=“no”})\\&\quad*P(\text{Student}|\text{buys=“no”})*P(\text{Credit}|\text{buys=“no”})\end{aligned}$$

购买预测问题

X =(age<=30, Income=medium, Student=yes, Credit_rating= Fair)

- 为具体计算，首先统计两类各个特征的条件概率

P(age="<30" | buys="yes") = 2/9=0.222

P(age="<30" | buys="no") = 3/5 =0.6

P(income="medium" | buys="yes")= 4/9 =0.444

P(income="medium" | buys="no") = 2/5 = 0.4

P(student="yes" | buys="yes)= 6/9 =0.667

P(student="yes" | buys="no")= 1/5=0.2

P(credit_rating="fair" | buys="yes")=6/9=0.667

P(credit_rating="fair" | buys="no")=2/5=0.4

Age	Income	Student	Credit_rating	Buys_computer
<=30	high	no	fair	no
<=30	high	no	excellent	ho
30...40	high	ho	fair	yes
>40	medium	no	fair	yes
>40	low	yes	fair	yes
>40	low	yes	excellent	no
31...40	low	yes	excellent	yes
<=30	medium	no	fair	no
<=30	low	yes	fair	yes
>40	medium	yes	fair	yes
<=30	medium	yes	excellent	yes
31...40	medium	no	excellent	yes
31...40	high	yes	fair	yes
>40	medium	no	excellent	no

- 然后，计算总的条件概率和先验概率：

P(X|buys="yes")= 0.222 x 0.444 x 0.667 x 0.667 =0.044

P(X|buys="no") = 0.6 x 0.4 x 0.2 x 0.4 =0.019

P(buys="yes")=0.643，P(buys="no")=0.357

- 最终，计算该用户购买电脑的概率：

$$P(\text{buys="yes"}|X) = \frac{0.044*0.643}{0.044*0.643+0.019*0.357} = 80.7\%$$

手写数字识别

- 输入X：图片的像素值

- 输出Y：0-9共10个类别

手写数字识别

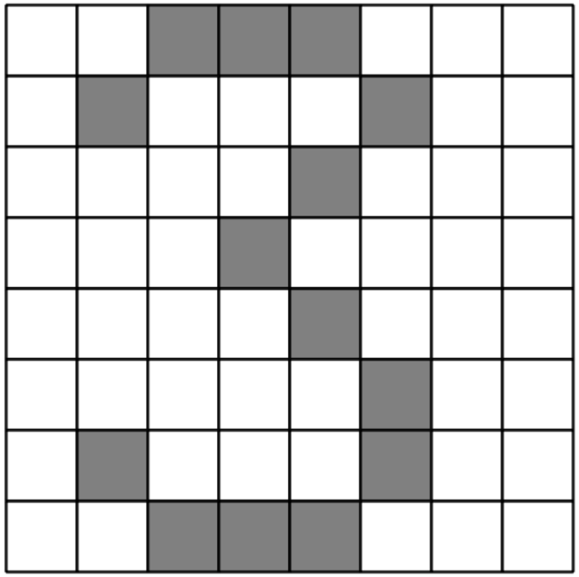

- 问题的简化与假设：
  - 假设图片压缩为16*16的网格
  - 每个格子仅有两个取值，即1（黑色）和0（白色）
  - 每个格子相互独立
  - 输入被转换为一个特征的向量

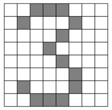

$$X =< X_{0,0} = 1, X_{0,1} = 0, X_{0,2} = 1, \dots, X_{15,15} = 0 >$$

- 虽然图片特征维度高，仍可建模为朴素贝叶斯分类模型

$$P(Y, X_{0,0}, \dots, X_{15,15}) = P(Y) \prod_{i,j} P(X_{i,j} | Y)$$

手写数字识别

$$P(Y,X) = P(Y)\prod_{i,j} P\left(X_{i,j}|Y\right)$$

$P(Y)$

1	0.1
2	0.1
3	0.1
4	0.1
5	0.1
6	0.1
7	0.1
8	0.1
9	0.1
0	0.1

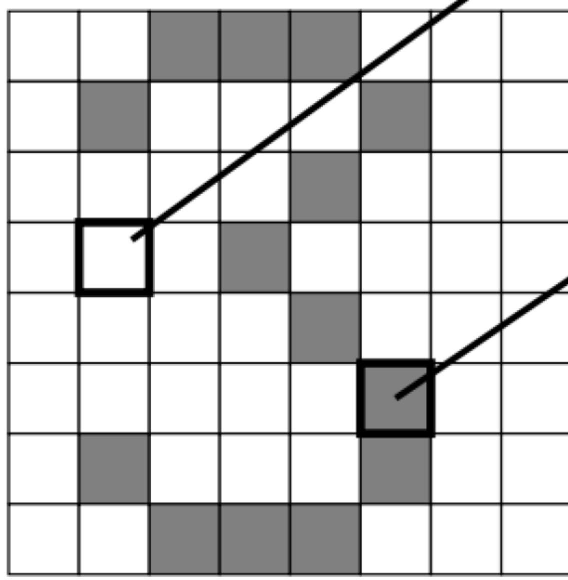

$P(X_{3,1} = 1|Y)$

1	0.01
2	0.05
3	0.05
4	0.30
5	0.80
6	0.90
7	0.05
8	0.60
9	0.50
0	0.80

$P(X_{5,5} = 1|Y)$

1	0.05
2	0.01
3	0.90
4	0.80
5	0.90
6	0.90
7	0.25
8	0.85
9	0.60
0	0.80

手写数字识别

➢朴素贝叶斯分类（为简洁，这里仅列出了2和3两类）

$P(Y=2)=0.1$

$P(X=1|Y=2)=0.8$

$P(X=1|Y=2)=0.1$

$P(X=0|Y=2)=0.1$

$P(X=1|Y=2)=0.01$

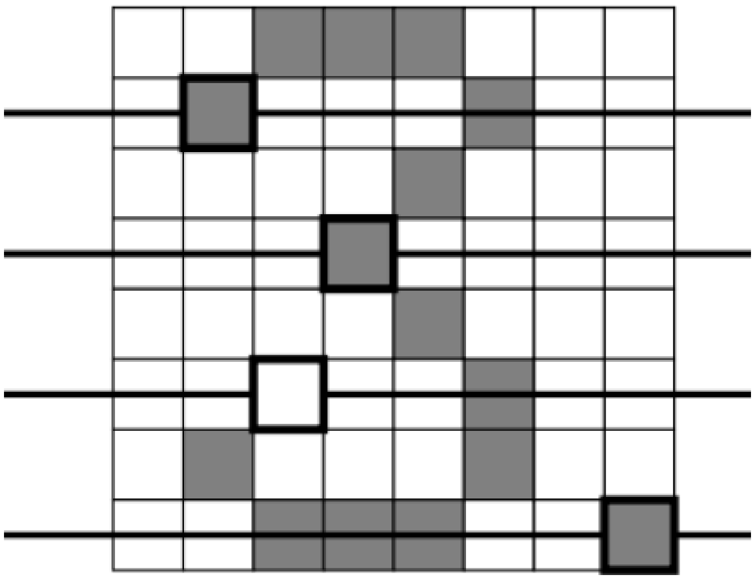

$P(Y=3)=0.1$

$P(X=1|Y=3)=0.8$

$P(X=1|Y=3)=0.9$

$P(X=0|Y=3)=0.7$

$P(X=1|Y=3)=0.0$

$P(X,Y=2)=8*10^{-6}$

分类结果为2！

$P(X,Y=3)=0$

手写数字识别

➢使用平滑过后的普通朴素贝叶斯分类：

$P(Y=2)=0.1$

$P(X=1|Y=2)=0.79$

$P(X=1|Y=2)=0.11$

$P(X=0|Y=2)=0.11$

$P(X=1|Y=2)=0.02$

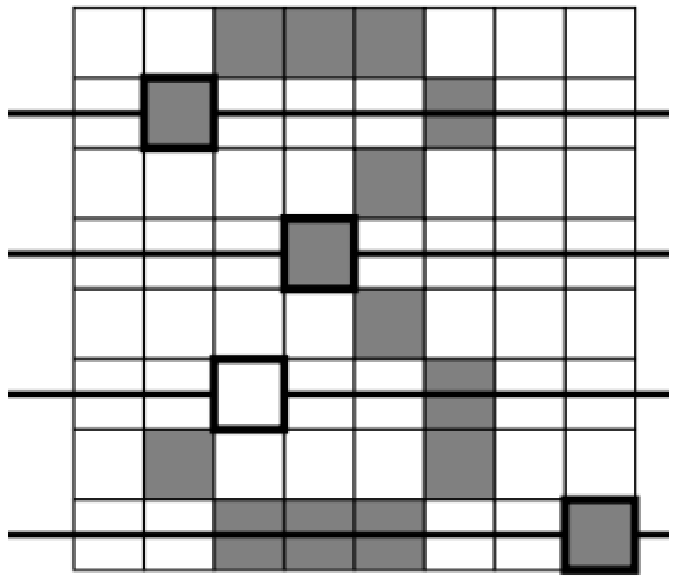

$P(Y=3)=0.1$

$P(X=1|Y=3)=0.79$

$P(X=1|Y=3)=0.89$

$P(X=0|Y=3)=0.70$

$P(X=1|Y=3)=0.01$

$P(X,Y=2)=1.9*10^{-5}$

分类结果为3

$P(X,Y=2)=4.9*10^{-4}$

朴素贝叶斯分类

- 优势：
  - 易于实现
  - 一定可解释性
  - 适合于类别型特征
  - 计算效率高
- 缺点：
  - 假定不同特征的影响是独立的
    - 现实中很多场景，特征影响是互相影响的
    - 例如，图片分类中，不同像素间有联系
    - 例如，疾病诊断中，是否发烧、是否咳嗽、血常规等

北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

谢谢

本课件仅供课上教学使用，对以下参考资料一并表示感谢：

清华大学 李建民老师课件《监督学习》

牛津大学 Marco Scutari教授课件《Understanding Bayesian Networks with Examples in R》

清华大学 徐华老师课件《贝叶斯分类》