



北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

第十一章 概率在数据科学的应用

张子威

2025年12月19日



提纲

- ① 数据与关联规则挖掘
- ② 贝叶斯分类
- ③ 从相关性到因果性



例子

- 1986年，一项针对肾结石研究，分析两种治疗方案A和B哪个更有效，有如下数据：

治疗方案 A	治疗方案 B
78% (273/350)	83% (289/350)

- 总体治愈率上，方案B表现更有效
- 但如果按照结石大小拆分成两组：

结石大小	治疗方案 A	治疗方案 B
小结石	93% (81/87)	87% (234/270)
大结石	73% (192/263)	69% (55/80)

- 哪里出了问题？



例子2

- (Science, 1975) 加州伯克利分校 (UC Berkeley) 研究生招生是否存在性别歧视。1973年部分数据如下

	总和		男生		女生	
	申请人数	录取率	申请人数	录取率	申请人数	录取率
数量	3024	43%	2175	47%	849	31%

- 但如果按照专业分层：


	总和		男生		女生	
	申请人数	录取率	申请人数	录取率	申请人数	录取率
专业A	933	64%	825	62%	108	82%
专业B	585	63%	560	63%	25	68%
专业C	792	34%	417	33%	375	35%
专业D	714	6%	373	6%	341	7%

- 哪里出了问题？



辛普森悖论

- **辛普森悖论**：探究两种变量（比如录取率与性别）是否具有相关性时的**整体趋势**，与按另一个变量（比如专业）分组后**每组趋势**不同甚至相反。
- 原因：分组变量起到了**混杂因素(confounder)**影响



- 例子中，女生更倾向于选择C/D专业，而C/D专业本身录取率低

	总和		男生		女生	
	申请人数	录取率	申请人数	录取率	申请人数	录取率
专业A	933	64%	825	62%	108	82%
专业B	585	63%	560	63%	25	68%
专业C	792	34%	417	33%	375	35%
专业D	714	6%	373	6%	341	7%




从相关性到因果性

- **相关性**(correlation) 与**相关性分析**(correlational analysis) 可以解决部分问题，但很多情况仍存在不足
- 反例：
 - 冰激凌销量与汽车抛锚率呈正相关 → 冰激凌损害发动机？
 - 是否进ICU与病人死亡率存在高相关性 → ICU是杀人机器？
 - 巧克力消耗量与获诺奖比例有高相关性 → 吃巧克力能获诺奖？
- 更复杂的问题：
 - 吸烟是否会导致肺癌？多喝牛奶是否能长寿？
 - 某个经济政策是否刺激了经济增长？
- 为了更好回答上述问题，需要引入**因果性**(causality)与**因果推断**(causal inference)



因果阶梯



因果阶梯:


- 第三层：反事实
- 第二层：干预
- 第一层：相关性



Judea Pearl
2011图灵奖得主



因果阶梯：例子



Level 3: Counterfactual

Given X and Y , what would Y have been if X had been different?

All else equal, what would my BMI have been if I had started that exercise regime?

Level 2: Intervention

If we force X to some value, how would that affect Y ?

If we force someone to start an exercise regime, what will be the effect on BMI?


Level 1: Association

Given X , what is Y likely to be?

Given someone on an exercise regime, what BMI are they likely to have?



因果阶梯：例子2



Level 3: Counterfactual

Given X and Y , what would Y have been if X had been different?

张三没打疫苗患了新冠，
假若他打了疫苗，是否
不会患新冠？

Level 2: Intervention

If we force X to some value, how would that affect Y ?

如果打疫苗，
疫情会减轻吗？

Level 1: Association

Given X , what is Y likely to be?

不同国家/地区/时间，
打疫苗越多的地方或
时期，疫情越重



三个级别的差别

- **相关性预测与干预决策**的差别：
 - **相关性**与**因果性**是两个不同的概念
 - 例子(Freedman, 1991): 小学生阅读能力与鞋尺寸有强相关, 可以根据小孩鞋尺寸预测其阅读能力
 - 年龄是一个关键的**混杂因素 (confounder)**
 - 在干预中, 即便能人为改变鞋尺寸, 也不会提高阅读能力



三个级别的差别

➤ 干预决策与反事实的差别：

➤ 干预决策通过寻找合理的对照，来评估干预效果


➤ 例：药物随机试验。将患病者随机分为两组，分别使用药物和安慰剂，进行评估。

药物效果： $Y_t(\text{实验组}) - Y_c(\text{对照组})$

➤ 反事实想象：已知事实作为条件


➤ 例，实事：张三吃药后病愈。

反事实：假若同一个张三不吃药，是否能病愈？
(不能找一个条件类似的李四作为对照)





因果的定义




- 亚里士多德（公元前384～前322）：四因说
“质料因、形式因、动力因、目的因”



- 哲学家休谟（1711-1776）：怀疑论
“我们无从得知因果之间的关系，只能得知某些事物总是会连结在一起”



- 哲学家康德（1724-1804）：
 - 先天分析判断：因果性等十二个范畴是知性固有的先天形式



- 哲学家波普尔（1902-1994）：证伪理论
 - “知识的积累依靠证伪”，因此证明因果关系存在这个目标就是错的



因果的定义

➤ 结果的原因 (Causes of Effects)

➤ 哲学家P. 苏佩斯 (1970):

- 如果事件 X 的出现提高了事件 Y 的概率

$$P(Y|X) > P(Y)$$

并且不存在第三个变量 U 使得

$$P(Y|X, U) \leq P(Y|U)$$

则称 X 是 Y 的原因。

- 虚假关联的例子：一个国家诺奖数量和巧克力消费量

$$P(\text{获诺奖}|\text{吃巧克力多}) > P(\text{获诺奖})$$

但是，存在国家 $U = u$ ，使得

$$P(\text{获诺奖}|\text{吃巧克力多}, U = u) \leq P(\text{获诺奖}|U = u)$$

所以巧克力和获诺奖有相关性，而非获诺奖的原因。



因果的定义

- 结果的原因 (Causes of Effects)
 - 哲学家Lewis定义 (1973): **反事实**
 - 如果当初事件 E 没有出现的话, 那么现在事件 D 就不会出现, 则说事件 E 是事件 D 的原因
 - 例: 吸烟与肺癌
- 已知事件:** 张三吸烟(记为 $E = 1$), 并且患了肺癌(记为 $D = 1$)
- 假若反事实世界中,** 张三不吸烟, 即 $E = 0$, 并且他没有患肺癌, 即 $D = 0$, 那么吸烟就是张三患肺癌的原因



因果的定义

- 结果的原因 (Causes of Effects)
- 2003年诺贝尔经济学获奖者Granger: 基于预测的因果关系
 - 如果 X 能为预测 Y 带来独一无二的信息, 并且 X 先于 Y 发生, 那么 X 是 Y 的原因

$$P(Y(t+1)|I(t)) \neq P(Y(t+1)|I_{-X}(t))$$

$I(t)$ 表示 t 时刻所有的信息, $I_{-X}(t)$ 表示去除 X 后的信息

- 优点: 实际计算中, 便于操作
- 缺点: 容易举出反例, 不是直观意义上的因果
 - 例: 闪电 X 总发生在雷声 Y 之前, 并且利用闪电 X 可以更好地预测雷声 Y , 但是闪电 X 不是雷声 Y 的原因
 - 存在一个公共的原因: 气流相撞 U 引起闪电 X 和雷声 Y
- 因此被命名为 “格兰杰因果”, 而非一般意义的因果



因果的定义

- 原因的结果 (Effects of Causes)
- 统计学家Nerman(1923)与Rubin(1974): **潜在结果理论** (Potential Outcome)
 - 考虑 X 对于结果 Y 的因果效应
 - 假若个体 i 暴露在 $X = 1$ 中, 记其潜在结果为 $Y_1(i)$
 - 假若个体 i 暴露在 $X = 0$ 中, 记其潜在结果为 $Y_0(i)$
 - 对于 i , X 对于 Y 的**个体因果效应** (Individual Causal Effect)
$$ICE(i) = Y_1(i) - Y_0(i)$$
 - **平均因果效应** (Average Causal Effect)
$$ACE(X \rightarrow Y) = \mathbb{E}(Y_1 - Y_0) = \mathbb{E}(Y_1) - \mathbb{E}(Y_0)$$
- 例: 一个降压药对于血压的影响, $X = 1$ 和 $X = 0$ 分别代表吃药或安慰剂, Y 即测量的血压值



➤ 随机实验 (Randomized Experiments)

➤ Fisher (1923) 形式化提出, 使因果作用被显示认知

➤ 核心思路: 通过随机, 消除不可观测变量的影响, 有效
估计平均因果效应ACE

➤ 例: 医生通过扔硬币, 决定患者服用药物或者安慰剂

➤ 随机使得是否服药与潜在血压无关, 即 $X \perp (Y_1, Y_0)$


$$\begin{aligned} ACE(X \rightarrow Y) &= \mathbb{E}(Y_1) - \mathbb{E}(Y_0) \\ &= \mathbb{E}(Y_1|X = 1) - \mathbb{E}(Y_0|X = 0) \\ &= \mathbb{E}(Y|X = 1) - \mathbb{E}(Y|X = 0) \end{aligned}$$

➤ 常被认为是因果效应评价的“金标准” (gold standard)



随机试验




- 随机实验也存在一些缺陷
 - 实验成本，甚至关乎伦理
 - 无法评估个体因果效应
 - 很多时候无法进行随机化试验
 - 例如，想要研究经济政策对国家的影响
 - 但很多时候，会有大量**观测数据 (observational data)**
- 许多相关研究与数学工具：
 - 倾向性得分 (propensity score)
 - 工具变量 (instrumental variable)
 - 前/后门调整 (frontdoor/backdoor adjustment)
 -
- 仍然是一个活跃的研究前沿！






因果在数据科学的重要性

计算机视觉例子：物体识别^[1]



Yes



Maybe





No



因果在数据科学的重要性

原因：相关性并不确保稳定 (stable)



At home



on beach



eating



in cage



in water



lying



on grass



in street



running






因果在数据科学的重要性

因果在数据科学/人工智能的重要性：

因果结构




T: 草地

X: 狗的特征

Y: 标签



草地 — 标签: 强相关性, 弱因果性
狗的特征 — 标签: 强相关性, 强因果性



因果特征更加稳定, 且具备可解释性



因果在数据科学的重要性

➤ 例：自动驾驶



智慧医疗



➤ 其它风险敏感应用：金融、法律、军事.....



北京航空航天大学计算机学院

School of Computer Science and Engineering, Beihang University

谢谢

本课件仅供课上教学使用，对以下参考资料一并表示感谢：
北京工商大学 耿直教授 《因果推断综述：因果作用、因果关系与归因》
Judea Pearl 《The Book of Why》
清华大学 崔鹏教授 《面向分布外泛化的稳定学习》
浙江大学 况琨教授 《大数据因果》